Raphaël Picard

Senior AI Engineer & Responsable IA

Agents LLM en production · RAG · LLMOps · MCP · Python · TypeScript · GCP

Lyon · télétravail
raphaelpicard@outlook.fr
06 50 93 15 73
raphaelpicard.com
linkedin.com/in/raphael-picard
github.com/PicardRaphael

PROFIL

Plus de huit ans d'ingénierie logicielle, dont la mise en production d'agents IA. Depuis novembre 2025, Senior AI Engineer et responsable IA chez Neoteem, éditeur d'un ERP immobilier : je conçois et déploie des assistants IA utilisés au quotidien par les gestionnaires, en lecture seule sur leurs données, sous contrôle humain et évalués avant chaque version. Je porte la stratégie IA auprès de la direction, j'encadre le pôle IA et je forme les équipes.

7	**−33 %**	**64**	**3 à 4**
agents IA en production	de coût d'inférence	cas rejoués 5 fois par version	personnes encadrées

COMPÉTENCES CLÉS

- **IA générative (GenAI) et agents** : LangGraph, agents ReAct, multi-agents, human-in-the-loop, Gemini (Vertex AI), Claude, prompt engineering
- **RAG et données** : RAG hybride (plein texte + pgvector, fusion RRF), reranking, embeddings, Unstructured
- **LLMOps et évaluation des LLM** : DeepEval (LLM-as-judge), golden sets, observabilité Langfuse (traces, coûts, latence), Pytest, Vitest, mutation testing
- **Outillage agentique** : Claude Code (skills, sous-agents, hooks), serveurs MCP (FastMCP), n8n
- **Back-end et cloud** : Python (FastAPI, Pydantic), TypeScript (Bun, Hono, Zod), PostgreSQL, OpenAPI, Google Cloud (GCP : Cloud Run), Docker, CI/CD
- **Front-end** : React, Next.js, TypeScript, Storybook

EXPÉRIENCE PROFESSIONNELLE

Senior AI Engineer & Responsable IA · Neoteem — **Nov. 2025 – aujourd'hui**
Éditeur d'un ERP pour les professionnels de l'immobilier · CDI, télétravail

Stratégie et leadership

- Architecture de chatbots spécialisés plutôt qu'un chatbot unique : proposée à la direction, adoptée en production
- Notes de décision pour la direction : organisation du pôle IA, arbitrages d'architecture (RAG ou base de connaissances, langage du pôle)
- Encadrement du pôle IA (3 à 4 personnes) ; formation des équipes techniques et métier (Claude Code, Claude Desktop, Claude Cowork, bonnes pratiques IA)

Sept agents IA en production, réunis dans trois assistants

- **NeoChat** : assistant des gestionnaires sur leurs données, courriels et documents ; moteur ReAct, 42 vues métier servies par 5 outils génériques
- **NeoSupport** : RAG hybride sur la documentation du logiciel ; demande une précision si la question est ambiguë, signale les manques de la documentation plutôt que d'inventer
- **NeoAgent** : comparaison de devis PDF (extraction multimodale, détection d'incohérences), rédaction d'annonces immobilières et de documents
- Sécurité dès la conception : données en lecture seule, 5 points de contrôle humain (interruptions LangGraph) ; aucun courriel envoyé ni document supprimé sans validation humaine

Qualité, évaluation et coûts (LLMOps)

- Golden set de 64 cas rejoués 5 fois (DeepEval) avant chaque version ; plus de 7 000 tests, CI à chaque PR
- Chaque conversation tracée dans Langfuse, coût et latence suivis par agent ; context caching : −33 % de coût d'inférence

Outillage agentique

- Claude Code déployé pour l'équipe : skills, sous-agents et hooks partagés sur 5 dépôts (TDD délégué, garde-fous)
- Base de connaissances interne reliée aux agents par 2 serveurs MCP maison

Back-end TypeScript

- Couche de données des agents entièrement réécrite en TypeScript (Bun, Hono, Zod, PostgreSQL), architecture hexagonale vérifiée en CI
- Score de mutation de 80 % exigé à chaque PR : les tests prouvent qu'ils détectent les régressions

Développeur full-stack et IA · Indépendant (EI) **Déc. 2022 – nov. 2025**

Une mission longue pour Royal Canin, puis des projets d'IA appliquée publiés en open source

Développeur front-end senior · Royal Canin (via Ekino) Déc. 2022 – avr. 2025

- Commerce en ligne dans plus de 100 pays : optimisation des parcours (B2B, B2C) et des performances
- Migration complète du code de JavaScript vers TypeScript, refonte en React Hooks, tests Jest et Testing Library
- Alignement de la refonte technique sur la feuille de route avec le PMO et les product owners

Projets d'IA appliquée, en open source sur GitHub Mars 2025 – nov. 2025

- **mcp-server-documentation** : serveur MCP (FastMCP) qui donne aux agents un accès unifié et à jour à la documentation de LangChain, LangGraph, Next.js et Tailwind
- **coder-crew** : quatre agents CrewAI (lead, back-end, front-end, tests) qui conçoivent, codent et testent une application ensemble ; un LLM par rôle, coûts suivis avec AgentOps
- **job-booster** : application RAG (FastAPI, Next.js, LangChain, Qdrant et reranker BGE) qui rédige courriels et lettres de motivation à partir d'une offre ; multi-LLM, traces Langfuse
- Agents LangGraph et OpenAI Agents SDK, API en Clean Architecture (FastAPI, Node.js), automatisations n8n

Développeur full-stack · Schoolmouv **Mars 2022 – déc. 2022**

Plateforme éducative interactive · CDI, télétravail

- Conception et développement du MVP à partir de zéro (React, Next.js, TypeScript) : R&D technique, architecture hexagonale
- Bibliothèque Storybook de composants ; API REST Express documentée avec Swagger ; tests Jest et Testing Library
- Encadrement technique de développeurs juniors ; coordination avec le PMO et le produit (priorités du MVP, jalons, livrables)

Développeur full-stack · Aixia Systèmes (pour Leasys Rent) **Sept. 2018 – mars 2022**

Refonte des outils numériques d'un loueur de véhicules · CDI, télétravail partiel

- PWA React (MUI) d'analyse automatique de documents (API Google Vision, 2018)
- Refonte complète du front-end et création d'un BFF GraphQL (Node.js, Apollo) devant les microservices
- Monorepo Lerna et CI/CD GitLab pour une équipe de 7 développeurs ; migration et sécurisation des API Symfony 3 → 5

PROJETS PERSONNELS OPEN SOURCE, EN PARALLÈLE DU POSTE (2026)

- **claude-forge** : méta-framework qui génère une configuration Claude Code validée, avec des hooks bloquants et un serveur MCP de 22 outils (FastMCP)
- **agentsdir** : outil en ligne de commande TypeScript (licence MIT) qui unifie l'architecture AGENTS.md de Codex, Cursor et opencode, la convertit pour Claude Code et la vérifie en CI
- **wow-forever** : assistant expert où l'IA ne calcule jamais, chaque chiffre venant d'un outil déterministe (serveur MCP de 8 outils, plugin Claude Code, plus de 400 fichiers de tests)

FORMATION ET CERTIFICATS

- **Concepteur développeur web**, titre RNCP de niveau 6 (bac + 4) · O'clock, 2018-2019
- **Développeur logiciel**, titre RNCP de niveau 5 (bac + 2) · O'clock, 2018
- **Anthropic Academy** : *Claude Code in Action* · *Claude with the Anthropic API* · *Introduction to Agent Skills* · *Introduction to Model Context Protocol*
- **Hugging Face / Google** : *AI Agents Fundamentals*

LANGUES

Français : langue maternelle · **Anglais** : B1, technique et opérationnel ; documentation et formations suivies en anglais